

המרכז הבינתחומי
The Interdisciplinary Center

בית ספר "אפי ארזי" למדעי המחשב
The Efi Arazi school of computer science

סמסטר ב' תשע"ו
Spring 2016

מבחן מועד ב בלמידה ממוכנת
Machine Learning Exam B

Lecturer : Prof Ariel Shamir
Time limit : 3 hours
No additional material is allowed for use!

מרצה : פרופ אריאל שמיר
משך המבחן : 3 שעות
אין להשתמש בחומר עזר!

Answer 5 out of 6 from the following
questions (each one is 20 points)

יש לענות על 5 מתוך 6 השאלות הבאות
לכל השאלות משקל שווה (20 נקודות)

בהצלחה!
Good Luck!

שאלה 1

ידוע כי מסוג מסוג support vector machine (SVM) בצורתו הפשוטה ביותר פותר את בעיית האופטימיזציה הבאה (המנוסחת בצורה הראשונית = primal):

$$\text{Minimize } \frac{1}{2} \|\mathbf{w}\|^2$$
$$\text{subject to: } \forall x^{(d)} \in D, t_d(\mathbf{w} \cdot x^{(d)} + w_0) - 1 \geq 0$$

- א. נתון כי $x^{(d)}$ הוא מופע מקבוצת האימון D . הגדירי מה משמעות כל שאר הסימנים בנוסחאות והסבירי מה מנסה האופטימיזציה להביא לאופטימום?
- ב. מה המשותף לאלגוריתם SVM ולאלגוריתם הפרספטון? הסבירי!
- ג. מה המשותף לאלגוריתם SVM ולאלגוריתם KNN? הסבירי!
- ד. הסבירי כיצד ניתן להשתמש באלגוריתם KNN לפתרון בעיית רגרסיה
- ה. הציעי דרך שבה ניתן להגדיר אלגוריתם SVM לפתרון לבעיית רגרסיה (רמז: הציעי ניסוח לבעיית אופטימיזציה אותה יש לפתור כדי להגדיר SVM עבור בעיית רגרסיה)

שאלה 2

- א. הסבירי מהו ממד רגישות של אלגוריתם למידה?
- ב. לאיזה משני המדדים קשורה "רגישות" – bias or variance? הסבירי!
- ג. האם עץ החלטות כפי שנלמד בכיתה (עם information gain) הוא אלגוריתם עם רגישות גבוהה או נמוכה? הסבירי!
- ד. נניח כי בנינו K עצי החלטה שונים מ-K קבוצות אימון **שונות** הציעי שיטה כיצד ניתן להשתמש ב-K עצים אלה כדי לעשות סיווג של מופע חדש?
- ה. האם בשיטה שהצעת ב-ד' הרגישות תעלה או תרד יחסית לעץ החלטה יחיד? הסבירי!
- ו. בהינתן קבוצת אימון עם m מופעים ו-n תכונות, כאשר m אינו גדול (כלומר m/K) הוא מספר קטן מידי לבנות עץ החלטה, הציעי שיטה לבנות K עצי החלטה שונים בעזרת קבוצת אימון.

שאלה 3

- משתמשים באלגוריתם k-means עם Euclidean distance לקבץ (cluster) את 6 הדוגמאות הדו-מימדיות הבאות ל-2 מרכזים: $A1=(1,7)$, $A2=(4,7)$, $A3=(5,5)$, $A4=(7,3)$, $A5=(8,1)$, $A6=(6,1)$
- א. ציירי מרחב דו מימדי בגודל 10 על 10 (מ-0 עד 10 בכל ציר) וסמני את 6 הדוגמאות.
 - ב. מלאי את טבלת **רבעי** המרחקים (בלי להוציא שרש) בין כל זוג דוגמאות. שימי לב כי אפשר להשתמש ברבע המרחקים באלגוריתם k-means במקום המרחק האוקלידי האמיתי כי יחס הסדר בין המרחקים ישמר:

	A1	A2	A3	A4	A5	A6
A1	0					
A2	X	0				
A3	X	X	0			
A4	X	X	X	0		
A5	X	X	X	X	0	
A6	X	X	X	X	X	0

- ג. בהנחה שבאיתחול האלגוריתם k-means אנחנו בוחרים את שני המרכזים בתור A1 ו-A3. הראי את החישובים בהרצת האיטרציה הראשונה של האלגוריתם ומצאי את שתי הקבוצות (clusters) שנוצרו ואת המרכזים החדשים.
- ד. המשיכי להריץ את החישובים באלגוריתם ומצאי את הקבוצות והמרכזים לאחר כל איטרציה עד התכנסות. כמה איטרציות נדרשו עד להתכנסות?
- ה. הסבירי כיצד ניתן למדוד את טיב הקיבוץ שנוצר?
- ו. האם הקיבוץ שנוצר הוא אופטימאלי? אם כן הסבירי מדוע! ואם לא – הסבירי כיצד ניתן יהיה לשפר את הקיבוץ ותני דוגמא?

שאלה 4

נתונה קבוצת אימון עם m מופעים שלהם n תכונות. אנו רוצים לבנות מסווג בינארי (בין שתי קבוצות MAP (B-I A

- הסבירי איזה הסתברויות עלינו להעריך כדי לסווג מופע חדש x ? (כולל נוסחה)
- הסבירי מה ההנחה הנאיבית ב-naïve bayes ומדוע צריך אותה? (כולל נוסחה)
- הסבירי כיצד מחושבות ההסתברויות שבסעיף א בשיטת parzen window? (כולל נוסחה)
- האם שיטת parzen window גם היא נאיבית? הסבירי!
- האם יתכן שהסתברות כלשהי ב- a תהיה 0 בשיטת naïve bayes פשוטה? אם כן הסבירי מתי ואיך פותרים זאת. אם לא הסבירי מדוע.
- האם יתכן שהסתברות כלשהי ב- a תהיה 0 בשיטת parzen window? אם כן הסבירי מתי ואיך פותרים זאת. אם לא הסבירי מדוע.

שאלה 5

- הסבירי מהן הבעיות בלמידה במימדים גבוהים של מרחב הדוגמאות (דוגמאות עם הרבה מאוד תכונות או features)?
- האם יש פתרון אופטימאלי לבחור תת קבוצה של תכונות בו פתרון בעיית סיווג תהיה טובה ביותר? אם כן הסבירי מהו הפתרון, אם לא הסבירי מדוע.
- תארי בקיצור את שתי הגישות המקובלות לפתרון בעיית למידה במימדים גבוהים בלמידה חישובית
- הסבירי מה ההבדל בין הגישות של סעיף ג לשיטה של סעיף ב.
- הסבירי מהם מרכיבים ראשיים (Principal Components), כיצד הם נבחרים באלגוריתם PCA וכיצד הם עוזרים לפתרון הבעיה.
- במשימת סיווג, איזו בעיה יכולה להיווצר מכך ש-PCA אינו מתייחס למידע של ה-class בקבוצת האימון? תני דוגמא (ניתן בצירוף) לקבוצת אימון בה תיווצר בעיה זו.

שאלה 6

- הגדירי מהו training error ומהו true error?
- הסבירי מהו מצב overfitting באלגוריתם למידה?
- אנו רוצים אומדן ל-true error באלגוריתם למידה כלשהו. הציעי שתי שיטות שונות לבנות אומדן כזה: שיטה אחת כאשר גודל קבוצת האימון קטן ושיטה שנייה כאשר גודל קבוצת האימון גדול.
- נניח שהמדד שבחרנו ב- g נקרא test error. הסבירי מה יקרה לטעות זו בתלות בגודל קבוצת האימון (מה קורה ל-test error ככל שקבוצת האימון הולכת וגדלה?) הסבירי מדוע! הסבירי מה יקרה ל-training error בתלות בגודל קבוצת האימון? הסבירי מדוע!
- הסבירי כיצד ניתן להשתמש במידע בסעיף ד כדי לדעת האם אנו במצב של overfitting ומה (אולי) ניתן לעשות כדי לפתור זאת?

בהצלחה

